



TRABAJO GMS

Aplicación de Inteligencia Artificial a procesos administrativos y logísticos en empresas

Nombre y Apellidos Autor: Alonso Gómez Jiménez

Tutor GMS: José Javier Bermúdez Luque

Fecha Presentación 11/10/2025



Índice

1. Resumen
2. Introducción.
3. Objetivos del GMS desarrollado.
4. Metodología y procedimiento
5. Conclusiones
6. Bibliografía.
7. Anexos (opcional).



Resumen

El objetivo de este trabajo de fin de máster ha sido investigar la viabilidad de un sistema modular de inteligencia artificial para automatizar procesos administrativos y logísticos en pequeñas y medianas empresas. El sistema se estructura en tres módulos principales: un módulo de extracción de facturas capaz de extraer información esencial de los documentos de manera estructurada, un planificador automático de horarios que optimiza la asignación de personal según la demanda histórica y restricciones operativas, y finalmente, un chatbot para la gestión de pedidos a proveedores.

Cada módulo fue investigado para ser diseñado, implementado y evaluado de manera independiente mediante datos simulados y reales que representan escenarios reales de PYMEs, permitiendo validar su eficacia y robustez. Además, se propone una arquitectura escalable que facilita la futura integración de los módulos, garantizando la creación de un sistema unificado y eficiente. Este trabajo demuestra que un enfoque modular e iterativo basado en Inteligencia Artificial puede mejorar significativamente la gestión operativa de las empresas, optimizando recursos, reducir los errores y facilitar la toma de decisiones estratégicas.

Introducción

En el contexto actual, las pequeñas y medianas empresas (PYMEs) se enfrentan a desafíos crecientes relacionados con la eficiencia operativa y la gestión de recursos. La automatización de procesos administrativos y logísticos surge como una solución clave para reducir errores, optimizar tiempos y mejorar la toma de decisiones. La inteligencia artificial ofrece herramientas capaces de analizar grandes volúmenes de información, generar predicciones y facilitar interacciones inteligentes entre empleados y los sistemas de gestión.

En el presente trabajo de fin de máster propongo el desarrollo de un sistema modular basado en técnicas de IA que automatice tareas comunes en PYMEs, centrándome en tres áreas fundamentales: la revisión de facturas, la planificación de horarios laborales y la gestión de pedidos mediante un asistente conversacional. La metodología adoptada combina un enfoque iterativo y modular, lo que permite desarrollar, evaluar y optimizar cada componente de manera independiente, asegurando la escalabilidad y la integración futura de los módulos en un sistema unificado.

Por otro lado, este enfoque no solo busca mejorar la eficiencia operativa, sino también demostrar cómo la IA puede aplicarse de manera práctica y accesible en entornos



empresariales cotidianos, ofreciendo soluciones concretas a problemas frecuentes y contribuyendo a la profesionalización de la gestión interna de las PYMEs.

Objetivos del GMS

El objetivo general es desarrollar e investigar un sistema modular basado en técnicas de inteligencia artificial que automatice tareas administrativas y logísticas comunes en empresas, como la revisión de facturas, la planificación de horarios y la gestión de pedidos mediante asistentes conversacionales.

Los objetivos específicos se basan en implementar un módulo de revisión de facturas capaz de detectar errores comunes y extraer estructuradamente las facturas mediante procesamiento de texto y reglas automatizadas. Permitiendo a las empresas calcular el escandallo de cada producto y su variación a lo largo del tiempo.

Además, investigaré la viabilidad de un planificador automático de horarios laborales que considere la disponibilidad de los empleados, las necesidades de la empresa y las restricciones operativas. Además, de optimizar la distribución de la plantilla en torno a una demanda calculada en base a un histórico de ventas, festividades y eventos que haya en la zona.

Para concluir, llevare a cabo el desarrollo de un chatbot que permita a los empleados gestionar pedidos a proveedores a través de un sistema conversacional controlado.

Para el correcto análisis de los proyectos deberé evaluar el funcionamiento de cada módulo de manera independiente mediante datos simulados y reales que representen escenarios comunes de una empresa. Así mismo, será importante el proponer una arquitectura escalable que permita la futura integración total entre módulos.

Metodología y procedimiento

El enfoque metodológico general adopta una metodología modular e iterativa basada en CRISP-DM (Cross Industry Standard Process for Data Mining) (Durango Vanegas, 2023), que permite un desarrollo organizado, flexible y orientado a resultados.

El proyecto combina investigación teórica y resultados prácticos siguiendo estos pasos principales:

- **Análisis del problema:** identificación de necesidades y objetivos en PYMES.
- **Diseño modular:** desarrollo de componentes autónomos y escalables.
- **Uso de tecnologías abiertas:** priorización de herramientas libres y accesibles.



- Preparación y comprensión de datos: limpieza, integración y análisis exploratorio (EDA).
- Modelado: aplicación y ajuste de algoritmos de aprendizaje automático.

Módulo 1: Desarrollo extractor inteligente de facturas

[Ver diagrama de flujos del módulo.](#) (Ilustración 1)

Aplicación de OCR, [PaddleOCR y su pipeline TableStructureV2](#) (Ilustración 2), para extraer texto buscando el layout de la tabla y su información. Como indican en [Automatic Extraction of PDF Table Data Based on Deep Learning](#): “PaddleOCR admite el aprendizaje multitarea, incluyendo la detección de texto, el reconocimiento de texto y el análisis de diseño, entre otros. Esto le permite comprender de manera integral la estructura de los documentos PDF, especialmente aquellos que contienen tablas. [...] PaddleOCR ofrece un rendimiento excepcional al procesar la mayoría de las tablas, alcanzando una tasa de precisión de reconocimiento de hasta el 93 %. Sin embargo, al tratar con tablas complejas que contienen celdas combinadas y marcas de agua, aún pueden presentarse problemas como caracteres redundantes y errores de reconocimiento.” (Yang, W., & Yu, M., 2025). PaddleOCR nos dará la posición de las distintas celdas, textos y columnas de las facturas de los pdfs en un formato estructurado: JSON. Como en el caso de las facturas las tablas son muy variadas y complejas no podremos confiar plenamente en este proceso. Sin embargo, ofrecen una información muy valiosa que será usada más adelante.

El conjunto de datos utilizado para el entrenamiento se construyó a partir de facturas reales etiquetadas manualmente, en los que cada fila fue identificada con su clase correspondiente. Posteriormente, las características fueron normalizadas y divididas en subconjuntos de entrenamiento (80%) y validación (20%) como recomienda (Díaz Romero, S., Sanyer Mosquera, W., & Menéndez Campos, J., 2021).

Continuando con la estructuración de la información. Destacar para este proceso el uso de reglas básicas (regex, validaciones) para detectar errores (totales incorrectos, campos vacíos, duplicados), la clasificación del tipo de factura por contenido (compra, alquiler, servicios...) y finalmente la división de la información de la tabla en filas según la posición “y” de los textos reconocidos para analizar las filas por separadas. Esto será útil también para entrenar el modelo MLP.

El modelo de clasificación se entrena utilizando un Perceptrón Multicapa (MLP), una red neuronal de tipo *feed-forward* compuesta por varias capas densamente conectadas (Botia, J. F, 2009). Este modelo recibe como entrada [un vector de características extraído de cada fila](#) (Ilustración 3) y genera como salida una etiqueta de clase que indica si la fila corresponde a



un encabezado, una línea de producto o una línea no relevante. Las características empleadas en la entrada combinan tanto información textual como estructural del documento, e incluyen variables tales como: Embeddings del texto OCR (representaciones semánticas del contenido), posiciones y dimensiones de la fila en el documento (tokens de la fila, posición normalizada del 0 al 1, distancia desde el header más probable), número de palabras o tokens por fila, porcentaje de caracteres numéricos, si contiene cantidades o precios, similitud semántica y léxica con productos de la base de datos, similitud semántica y léxica con diccionario de encabezados. Como nos indica Langley P en su investigación *Selection of relevant features in machine learning*, para poder entrenar un modelo satisfactoriamente es de gran importancia saber discernir entre features importantes e irrelevantes. Siendo importante elegir aquellos que ayuden a describir las características de cada etiqueta a clasificar y reducir los falsos positivos (Langley, P, 1994).

Como se explica libro *Introducción al machine learning con TensorFlow* (Álvarez Fidalgo, 2021): El proceso de entrenamiento de una red neuronal pasa por optimizar la función de coste encontrando los pesos, adecuados para cada una de las capas. Durante el entrenamiento, el modelo aprenderá a minimizar la función de pérdida de entropía cruzada a través de Backpropagation, en este caso, ajustando sus pesos mediante el optimizador Adam. Finalmente, siguiendo la investigación *An analysis of early stopping and dropout regularization in deep learning* se podría emplear una tasa de aprendizaje inicial de 0.001 y un número fijo de épocas determinado de forma experimental, aplicando además técnicas de regularización como *dropout* y *early stopping* para evitar el sobreajuste (Sitaula, C., & Ghimire, N., 2017).

Al finalizar el proceso, es necesario evaluar el rendimiento del modelo mediante métricas estándar de clasificación, tales como precisión (accuracy), recall, F1-score y matriz de confusión (Borja-Robalino, R., Monleón-Getino, A., & Rodellar, J., 2020), lo que permitirá identificar los tipos de errores más frecuentes y ajustar los hiperparámetros de manera iterativa.

Finalmente, el entrenamiento se ha llevado a cabo y el MLP es capaz de identificar satisfactoriamente las filas de la tabla que son encabezados, productos y las que no son nada. Esta información se le puede pasar a un LLM para que extraiga la información con un output estructurado entendiendo el contexto en el caso de que haya campos dudosos. O por otro lado si tanto el encabezado como los productos predichos tienen el mismo número de campos y estos están en una posición media de los textos en cuanto al eje "y", será posible determinar sus valores fila/columna con reglas heurísticas.

Módulo 2: Investigación generación de horarios

[Diagrama de flujo módulo 2.](#) (Ilustración 4)



Para llevar este módulo a cabo, el conjunto de datos utilizado para el entrenamiento se debería de construir a partir de historial de horarios generados estructuradamente. Es importante mantener la calidad de los datos y validar su recolección. Como indican en el estudio ETL (extracción, transformación y carga) o intercambio de información entre aplicaciones empresariales con el fin de crear un prototipo: “los datos son extraídos de los sistemas fuentes, los cuales pasan por una secuencia de validaciones y transformaciones antes de que se carguen el sistema destino o la bodega de datos” (García, Y. M., Ibarra, C. H. O., Muñoz, H. E. P., & Moreno, E. R. R., p.123, 2018). En mi caso, [hice la carga inicial de históricos reales en base de datos relacional](#) (Ilustración 5), incluyendo 400 horarios durante varios años a través de un script que facilité la extracción de los archivos xmls.

Como señala Sánchez (2018), el análisis exploratorio de datos (EDA) permite comprender la estructura de los datos históricos, identificar patrones, anomalías y relaciones entre variables que afectan la demanda y asignación de empleados. En el contexto empresarial, este análisis es gran ayuda para detectar los turnos con mayor volumen de ventas y evaluar si la ordenación del personal ha sido adecuada. Asimismo, se analizarán las correlaciones entre demanda, eventos y clima, considerando factores como festividades, eventos deportivos o condiciones meteorológicas. Mediante coeficientes de correlación y análisis multivariante se identificarán las variables exógenas más influyentes para el modelo de forecasting.

Antes del modelado, es esencial el preprocesamiento y selección de atributos. Como destaca Ledesma Mejías (2021, p.9), este proceso consiste en elegir los atributos más relevantes para la variable objetivo. En este caso, se integrarán distintas fuentes historiales de horarios, ventas, perfiles de empleados y demanda estimada en un dataset unificado por fecha, turno y local, donde cada registro representará una unidad de análisis completa para la predicción de demanda y planificación de personal. Seguidamente se derivarán variables adicionales que faciliten al modelo la captura de patrones estacionales y dependencias externas. Entre ellas se incluyen: Variables temporales: día de la semana, mes, número de semana, festivo nacional/local, proximidad a eventos y variables exógenas: tipo de evento, importancia estimada del evento, clima (temperatura, lluvia, viento), afluencia turística estimada. Estas variables servirán como features que condicionan la predicción de la demanda y, en última instancia, la asignación óptima del personal.

Continuando con el pipeline, se aplicarán técnicas de escalado y normalización a variables numéricas continuas (ventas históricas, número de empleados, cobertura por turno) para que los modelos de machine learning funcionen correctamente y se evite que variables con magnitudes mayores dominen a la hora de entrenarlo. Lo más común es usar métodos



como Min-Max Scaling o Standardization según el tipo de algoritmo a emplear. La normalización Mín-Máx por ejemplo es útil cuando se desea conservar información sobre los datos y ajustarlos a un rango específico ajustando el valor resultante en un umbral entre 0 y 1 (Solorzano, 2023).

Según Sadeghianpourhamami et al. (2019), *“el forecasting es el proceso de hacer proyecciones sobre eventos futuros utilizando datos históricos y análisis estadístico”*. En esta fase, el objetivo será predecir la demanda esperada por turno y por día a partir de datos históricos y variables exógenas. Para ello, se empleó LightGBM, un modelo eficiente para grandes volúmenes de datos y capaz de manejar variables categóricas y numéricas, además de capturar relaciones no lineales y ofrecer interpretabilidad (Ke, G., 2017). El modelo una vez entrenado se almacena mediante serialización (Pickle), permitiendo su reutilización en el pipeline de generación de horarios sin necesidad de reentrenamiento.

Con la demanda predicha, se implementa un modelo de optimización mediante programación por restricciones para generar los horarios de empleados. Según Linares y Ramos (2001, p.6), un modelo de optimización se compone de una función objetivo, variables y restricciones. En este caso:

- Variables: asignaciones binarias empleado–turno.
- Restricciones: disponibilidad, límite de horas semanales, cobertura mínima según demanda y coste laboral óptimo.
- Función objetivo: minimizar el coste total de personal manteniendo la cobertura y cumpliendo todas las restricciones.

El número de empleados requeridos se determina directamente a partir del output del modelo de predicción, garantizando una cobertura adecuada. El solver CP-SAT de Google OR-Tools genera automáticamente un horario óptimo que puede exportarse en JSON, CSV o integrarse en un dashboard web para su visualización y gestión.

Finalmente, se deberán comparar los horarios generados con los históricos, evaluando métricas como cumplimiento de demanda, cobertura de turnos, costes laborales y satisfacción de restricciones. Esto permite validar la efectividad del modelo y detectar posibles mejoras. Además, de probar escenarios especiales como días festivos, partidos de fútbol o eventos culturales para analizar cómo responde el sistema ante condiciones inusuales. Finalmente, es determinante analizar cómo cambian los resultados si la demanda prevista se altera, por ejemplo, incrementando o disminuyendo un 10-20%. Esto ayuda a medir la robustez del sistema y preparar planes de contingencia.

Módulo 3: Desarrollo chatbot asistente de pedidos

[Diagrama de flujo chatbot asistente de pedidos](#) (Ilustración 6).



Según el análisis en la investigación “Modelo de gestión logística para pequeñas y medianas empresas en México” cuatro de las áreas más importantes para la gestión de un Pyme son los inventarios, almacenamiento, producción y distribución, así como la aplicación de las herramientas que mejorarán el desempeño logístico de la cadena de suministro (Cano Olivos, P., Orue Carrasco, F., Martínez Flores, J. L., Mayett Moreno, Y., & López Nava, G., 2015). En este módulo nos centraremos en ayudar al inventario, haciendo de puente entre el negocio y el productor determinando cuánto y cuando pedir las existencias de un negocio, y atendiendo a la distribución. Facilitando el responder a las necesidades de las áreas productivas de un Pyme, que puede llegar a contar con cuellos de botella en la administración de su logística interna, suministrando confiablemente las materias primas que cumplan sus necesidades (Gómez, H. B. D., Cáceres, R. G. G., & Mancilla, N. P., 2008).

El chatbot actúa como intermediario autónomo, capaz de mantener conversaciones bidireccionales y coordinar la información entre ambos actores: El encargado de la empresa, que solicita productos o realiza consultas sobre pedidos. El proveedor, que confirma disponibilidad, precios, envíos o incidencias.

De este modo, el sistema permite mantener una conversación cruzada controlada, en la que el chatbot centraliza la interacción, filtra la información relevante y mantiene trazabilidad completa mediante registros (*logs*) de todas las conversaciones.

La Arquitectura general del sistema conversacional se implementará a través de una interfaz conversacional de mensajería (WhatsApp) admitiendo tanto entradas de texto como de audio.

La gestión del diálogo se estructura mediante un flujo conversacional modular y contextual, que permite al Agente de IA bifurcar o continuar conversaciones según las necesidades. Este agente se conecta a la API de un LLM para procesar texto y dispone de herramientas para registrar interacciones, mantener el historial de pedidos y sincronizarse con la base de datos interna de la empresa, accediendo a información actualizada sobre stock y pedidos.

El flujo conversacional es flexible y adaptativo, permitiendo tanto la comunicación entre el encargado y el chatbot (para generar pedidos y contactar con proveedores) como entre el proveedor y el chatbot (para actualizar estados y recibir notificaciones). Además, mediante un sistema de mensajería como Kafka, un webhook podría notificar al agente cuando el inventario alcance niveles mínimos, generando pedidos automáticos.

Con [n8n](#) (Ilustración 7) se implementará un sistema de herramientas y conversaciones que permita al agente recopilar información. Según Quisbert (2008), un agente percibe y actúa dentro de su entorno, adaptando su comportamiento según las peticiones recibidas.

Todas las interacciones se almacenarán en una base de datos de logs para trazabilidad. No obstante, como advierten Corozo y Jácome (2024, p.1), aunque la IA mejora la eficiencia en la atención al cliente, introduce riesgos en la privacidad y la seguridad, por lo que se deberán



aplicar medidas de protección, como autenticación de usuarios, permisos explícitos, cifrado y monitoreo continuo.

Conclusiones

El desarrollo de este trabajo de fin de máster ha permitido abordar de manera teórico-práctico la automatización de procesos administrativos y logísticos en pequeñas y medianas empresas, mediante un enfoque modular y basado en técnicas de inteligencia artificial. La investigación conjunta a ejemplos de los módulos ha demostrado que es posible mejorar la eficiencia operativa y la toma de decisiones a través de sistemas inteligentes, adaptados a las necesidades concretas de una PYME.

El módulo de extracción de facturas ha proporcionado una herramienta que es capaz de extraer la información de las facturas de una manera estructurada, facilitando la obtención de información valiosa como el escandallo de productos y su evolución temporal. La investigación del planificador automático de horarios ha mostrado su potencial para optimizar la asignación de recursos humanos, considerando tanto la disponibilidad de los empleados como las demandas operativas derivadas de históricos de ventas y eventos locales. Por último, el desarrollo del chatbot ha permitido simplificar y agilizar la gestión de pedidos mediante una interfaz conversacional, reduciendo errores y tiempos de respuesta en la interacción con proveedores.

La evaluación individual de cada módulo mediante escenarios simulados ha confirmado la robustez de las soluciones y ha permitido identificar áreas de mejora de manera controlada. Asimismo, la propuesta de una arquitectura escalable garantiza que los módulos puedan integrarse plenamente en un futuro, facilitando la creación de un sistema que sea unificado que pueda aprovechar al máximo la sinergia entre los distintos componentes.

En definitiva, este trabajo evidencia que un enfoque modular, iterativo y basado en IA no solo es viable, sino que aporta un valor tangible a la gestión operativa de las empresas, ofreciendo un camino hacia la automatización inteligente de procesos más críticos, logísticos y una mejora continua en la toma de decisiones estratégicas.

Bibliografía

Álvarez Fidalgo, I. Introducción al machine learning con TensorFlow. 2021



Botia, J. F. (2009). Redes Neuronales Artificiales de Base Radial como Clasificador Difuso: Una Aplicación al Diagnóstico Médico.

Borja-Robalino, R., Monleón-Getino, A., & Rodellar, J. (2020). Estandarización de métricas de rendimiento para clasificadores Machine y Deep Learning. *Revista Ibérica de Sistemas e Tecnologías de Informação*, (E30), 184-196.

Cano Olivos, P., Orue Carrasco, F., Martínez Flores, J. L., Mayett Moreno, Y., & López Nava, G. (2015). Modelo de gestión logística para pequeñas y medianas empresas en México. *Contaduría y administración*, 60(1), 181-203.

Corozo, K. L. E., & Jácome, W. L. C. (2024). Análisis de riesgos en la seguridad de la información con la implementación de IA en los sistemas de atención al cliente. *Revista Internacional de Estudios en Ciencias Administrativas STRATEGOS*, 4(2), 19-19.

Díaz Romero, S., Sanyer Mosquera, W., & Menéndez Campos, J. (2021). Selección de candidatos para encuestas mediante técnicas de machine learning (Doctoral dissertation, ESPO. FCNM).

Durango Vanegas, C. E., Giraldo Mejía, J. C., Vargas Agudelo, F. A., & Soto Duran, D. E. (2023). A Representation Based on Essence for the CRISP-DM Methodology. *Computación y Sistemas*, 27(3), 675-689.

García, Y. M., Ibarra, C. H. O., Muñoz, H. E. P., & Moreno, E. R. R. ETL (extracción, transformación y carga) o intercambio de información entre aplicaciones empresariales con el fin de crear un prototipo. *RETOS DE LA INVESTIGACIÓN EN INGENIERÍA DE SISTEMAS: APLICACIONES, HERRAMIENTAS Y DESARROLLOS*, 115. 2018

Gómez, H. B. D., Cáceres, R. G. G., & Mancilla, N. P. (2008). Las Pymes: costos en la cadena de abastecimiento. *Revista escuela de administración de negocios*, (63), 5-21.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30.

Sadeghianpourhamami, N., Benoit, D. F., Deschrijver, D., & Develder, C. (2019). Bayesian cylindrical data modeling using Abe-Ley mixtures. *Applied Mathematical Modelling*, 68, 629-642.

SANCHEZ, C. C., GIRALDO, L. M., PIEDRAHITA, C. C., Bonet, I., LOCHMULLER, C., TABARES, M. S., & PEÑA, A. (2018). Análisis comparativo entre: «el análisis exploratorio de datos» y los modelos de «árboles de decisión» y «k-means» en el diagnóstico de la malignidad en algunos exámenes de cáncer de mama. un estudio de caso. *Revista Espacios*, 39(28).

Solorzano, K. P. C. (2023). PREPROCESAMIENTO DE DATOS EN APRENDIZAJE AUTOMÁTICO SUPERVISADO: TÉCNICAS DE NORMALIZACIÓN.



Langley, P. (1994, November). Selection of relevant features in machine learning. In *Proceedings of the AAAI Fall symposium on relevance* (Vol. 184, pp. 245-271).

Ledesma Mejías, C. Minería de datos: pre-procesamiento. 2021: <http://hdl.handle.net/11000/26266>

Linares, P., Ramos, A., Sánchez, P., Sarabia, A., & Vitoriano, B. (2001). Modelos matemáticos de optimización. *Madrid, España*.

Quisbert, F. (2008). Agentes inteligentes: El siguiente paso en la inteligencia artificial.

Sitaula, C., & Ghimire, N. (2017). An analysis of early stopping and dropout regularization in deep learning. *International Journal of Conceptions on Computing and Information Technology*, 5(1), 17-20.

Yang, W., & Yu, M. (2025, January). Automatic Extraction of PDF Table Data Based on Deep Learning. In *Proceedings of the 2025 4th International Conference on Big Data, Information and Computer Network* (pp. 222-226).



Anexo:




Ilustración 1: Diagrama de flujos - Módulo 1: Extractor de facturas

Formulario de factura con campos para datos de cliente, proveedor, fecha, y una tabla de productos con columnas: Código, Descripción, EAN, Cant., Tarifa, Precio Neto, Neto Unit., IVA.

Formulario de factura complejo con múltiples secciones, incluyendo datos de cliente, proveedor, fecha, y una tabla de productos. Incluye también campos para el tipo de documento y el número de factura.

Formulario de factura con una tabla de resumen de la factura que incluye: Total neto, Valor impuestos, y Total Factura (EUR).

Formulario de factura complejo con una tabla de resumen de la factura que incluye: Total neto, Valor impuestos, y Total Factura (EUR).

Ilustración 2: Módulo 1: Extractor de facturas. Debug de la extracción de una tabla con TableStructureV2

[illegible]

Ilustración 3: Módulo 1: Extractor de facturas. Extracción de los features por filas.




Ilustración 4: Diagrama de flujos - Módulo 2: Generador de horarios.

```

    graph LR
      PD[Predicción Demanda] --> L[Locales]
      L --> T[Trabajadores]
      T --> TD[Trabajadores Disponibles]
      TD --> VH[Vehículos Históricos]
  
```

PREDICCIÓN DEMANDA

ID	FECHA	START_TIME	END_TIME	VENTAS_ESPERADAS	TICKETS_ESPERADOS	VERSION_MODELO	LOCAL_ID

LOCALES

ID	NOMBRE	DIRECCION

TRABAJADORES

ID	NOMBRE	ROL	ANTIGÜEDAD	COSTE_HORA

TRABAJADORES_DISPONIBILIDAD

ID_TRABAJADOR	DIAS_DISPONIBLES	SOLO_MANANA	SOLO_TARDE	SOLO_NOCHE	APOYO	TURNQ_PARTIDO	MAX_HORAS_MES

VEHICULOS_HISTORICOS

VENTA_ID	TIMESTAMP	CANTIDAD	TRANSACCIONES	LOCAL_ID

Ilustración 5: Módulo 2: Generador de horarios. Diagrama de base de datos.

